



TP558 - Tópicos Avançados em Machine Learning:

XGBoost: A Scalable Tree Boosting System



Abertura

- Contexto
 - Tree Boosting amplamente utilizado em ML
 - Alto desempenho preditivo
 - Aplicação em diferentes problemas de ML
- Problema
 - Crescimento do volume de dados
 - Maior demanda computacional
 - Necessidade de eficiência em larga escala
- Motivação
 - Desenvolvimento de um sistema de Tree Boosting escalável
 - Uso eficiente dos recursos computacionais



Introdução

OBJETIVO

- Apresentar o XGBoost, um sistema otimizado de Tree Boosting desenvolvido para tornar o treinamento de modelos de ML mais eficiente e escalável, especialmente em problemas com grandes volumes de dados.

Hipótese

- Manter o alto desempenho preditivo do Tree Boosting e melhorar sua eficiência computacional.



TREE BOOSTING

Alto desempenho preditivo



AVANÇOS ALGORÍTMICOS

Novas técnicas



OTIMIZAÇÕES DE SISTEMA

Melhor uso dos recursos computacionais



XGBOOST

Eficiência + Escalabilidade

Contribuições dos autores


Contribuição	Finalidade
Sistema end-to-end de Tree Boosting escalável	Viabilizar Tree Boosting eficiente em problemas de grande escala
Weighted Quantile Sketch	Encontrar pontos candidatos eficientes para divisão dos dados
Sparsity-Aware Algorithm	Lidar eficientemente com dados esparsos
Cache-Aware Block Structure	Melhorar a eficiência do acesso aos dados e possibilitar aprendizado <i>out-of-core</i>

Fundamentação Teórica

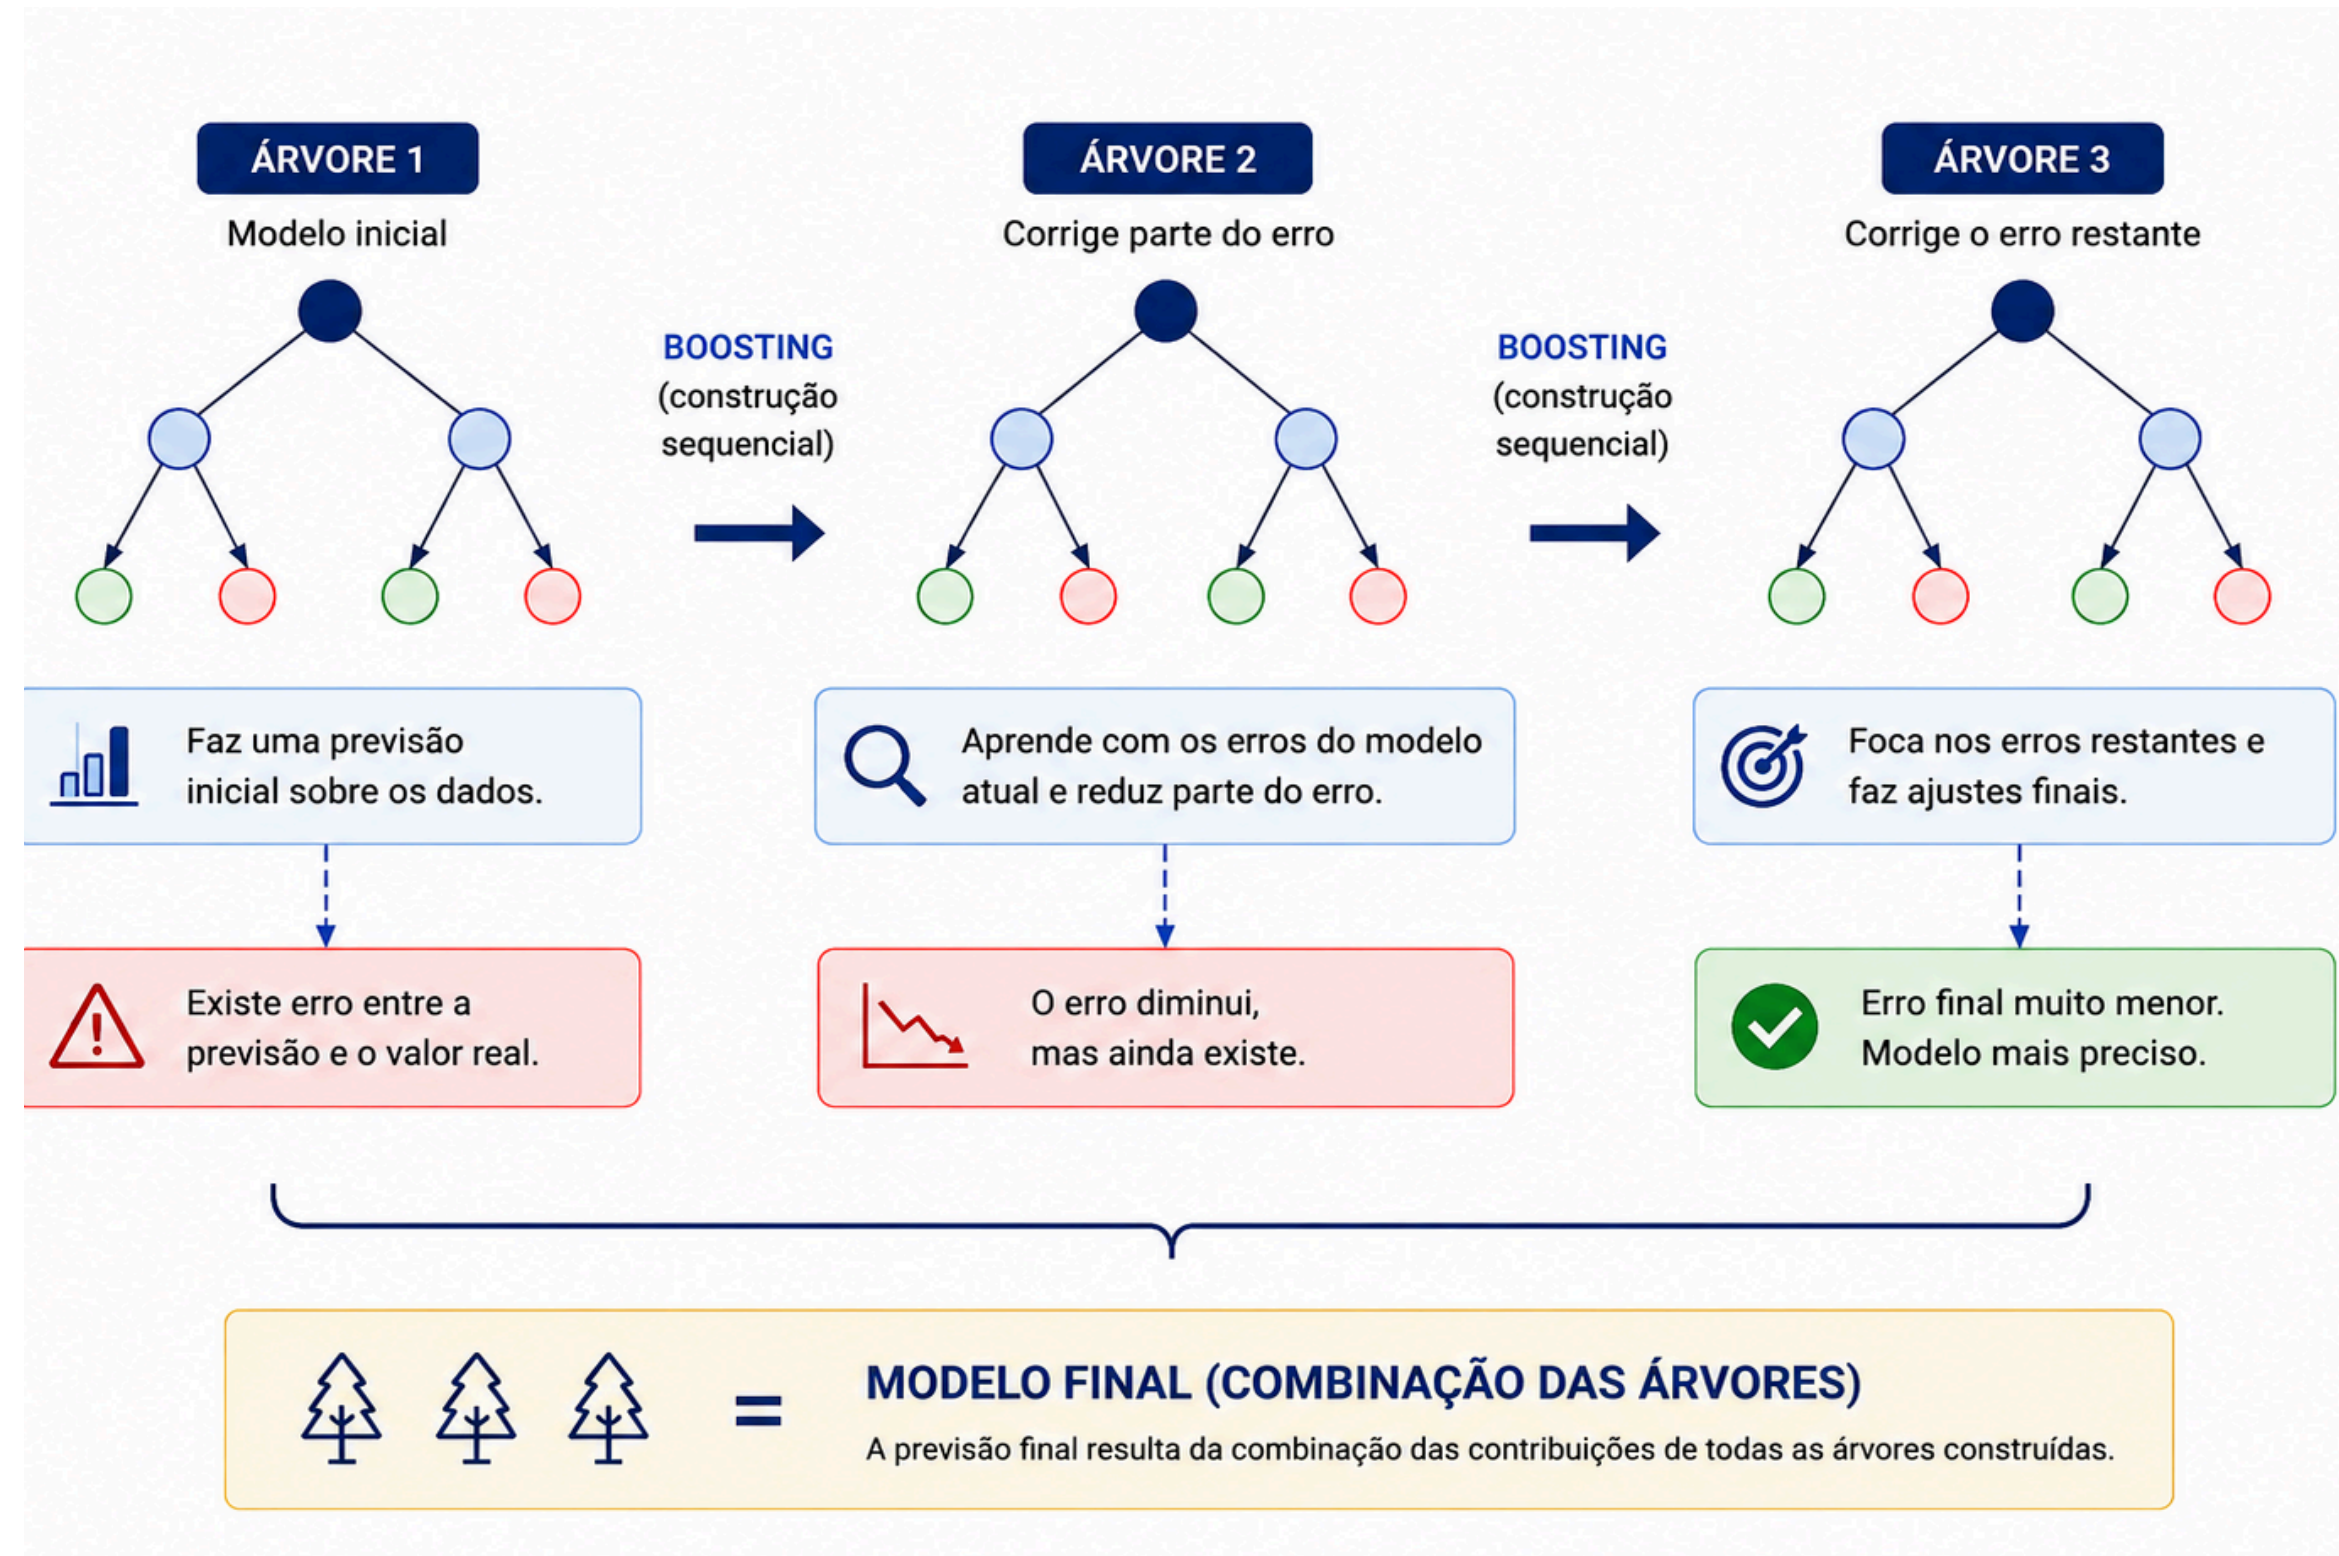
- **Árvore de Decisão:** Modelo de Machine Learning que realiza previsões por meio de uma sequência de perguntas sobre as características dos dados.

Funcionamento

- Cada nó realiza uma divisão (split) dos dados;
- Cada ramo representa um caminho de decisão;
- A previsão é obtida ao chegar a uma folha.



- **Tree Boosting:** Técnica que constrói árvores de decisão sequencialmente, em que cada nova árvore busca reduzir os erros do modelo formado pelas árvores anteriores.




- **Gradient Tree Boosting:** é um método de Tree boosting em que novas árvores são adicionadas sequencialmente, usando o gradiente da função de perda para orientar a melhoria do modelo.

Atualização aditiva da previsão

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i)$$

- **XG Boost:** XGBoost (eXtreme Gradient Boosting): sistema de Tree Boosting projetado para ser eficiente, flexível e escalável.



Função Objetivo Regularizada:

orienta o treinamento do XGBoost buscando reduzir os erros das previsões e controlar a complexidade do modelo.

$$\mathcal{L}(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k)$$

- **Gradiente de 1ª e 2ª Ordem no XG Boost**

1ª ordem

$$g_i = \partial_{\hat{y}_i^{(t-1)}} l(y_i, \hat{y}_i^{(t-1)})$$

g_i : indica como a perda varia em relação à previsão atual, orientando a correção do modelo.

2ª ordem

$$h_i = \partial_{\hat{y}_i^{(t-1)}}^2 l(y_i, \hat{y}_i^{(t-1)})$$

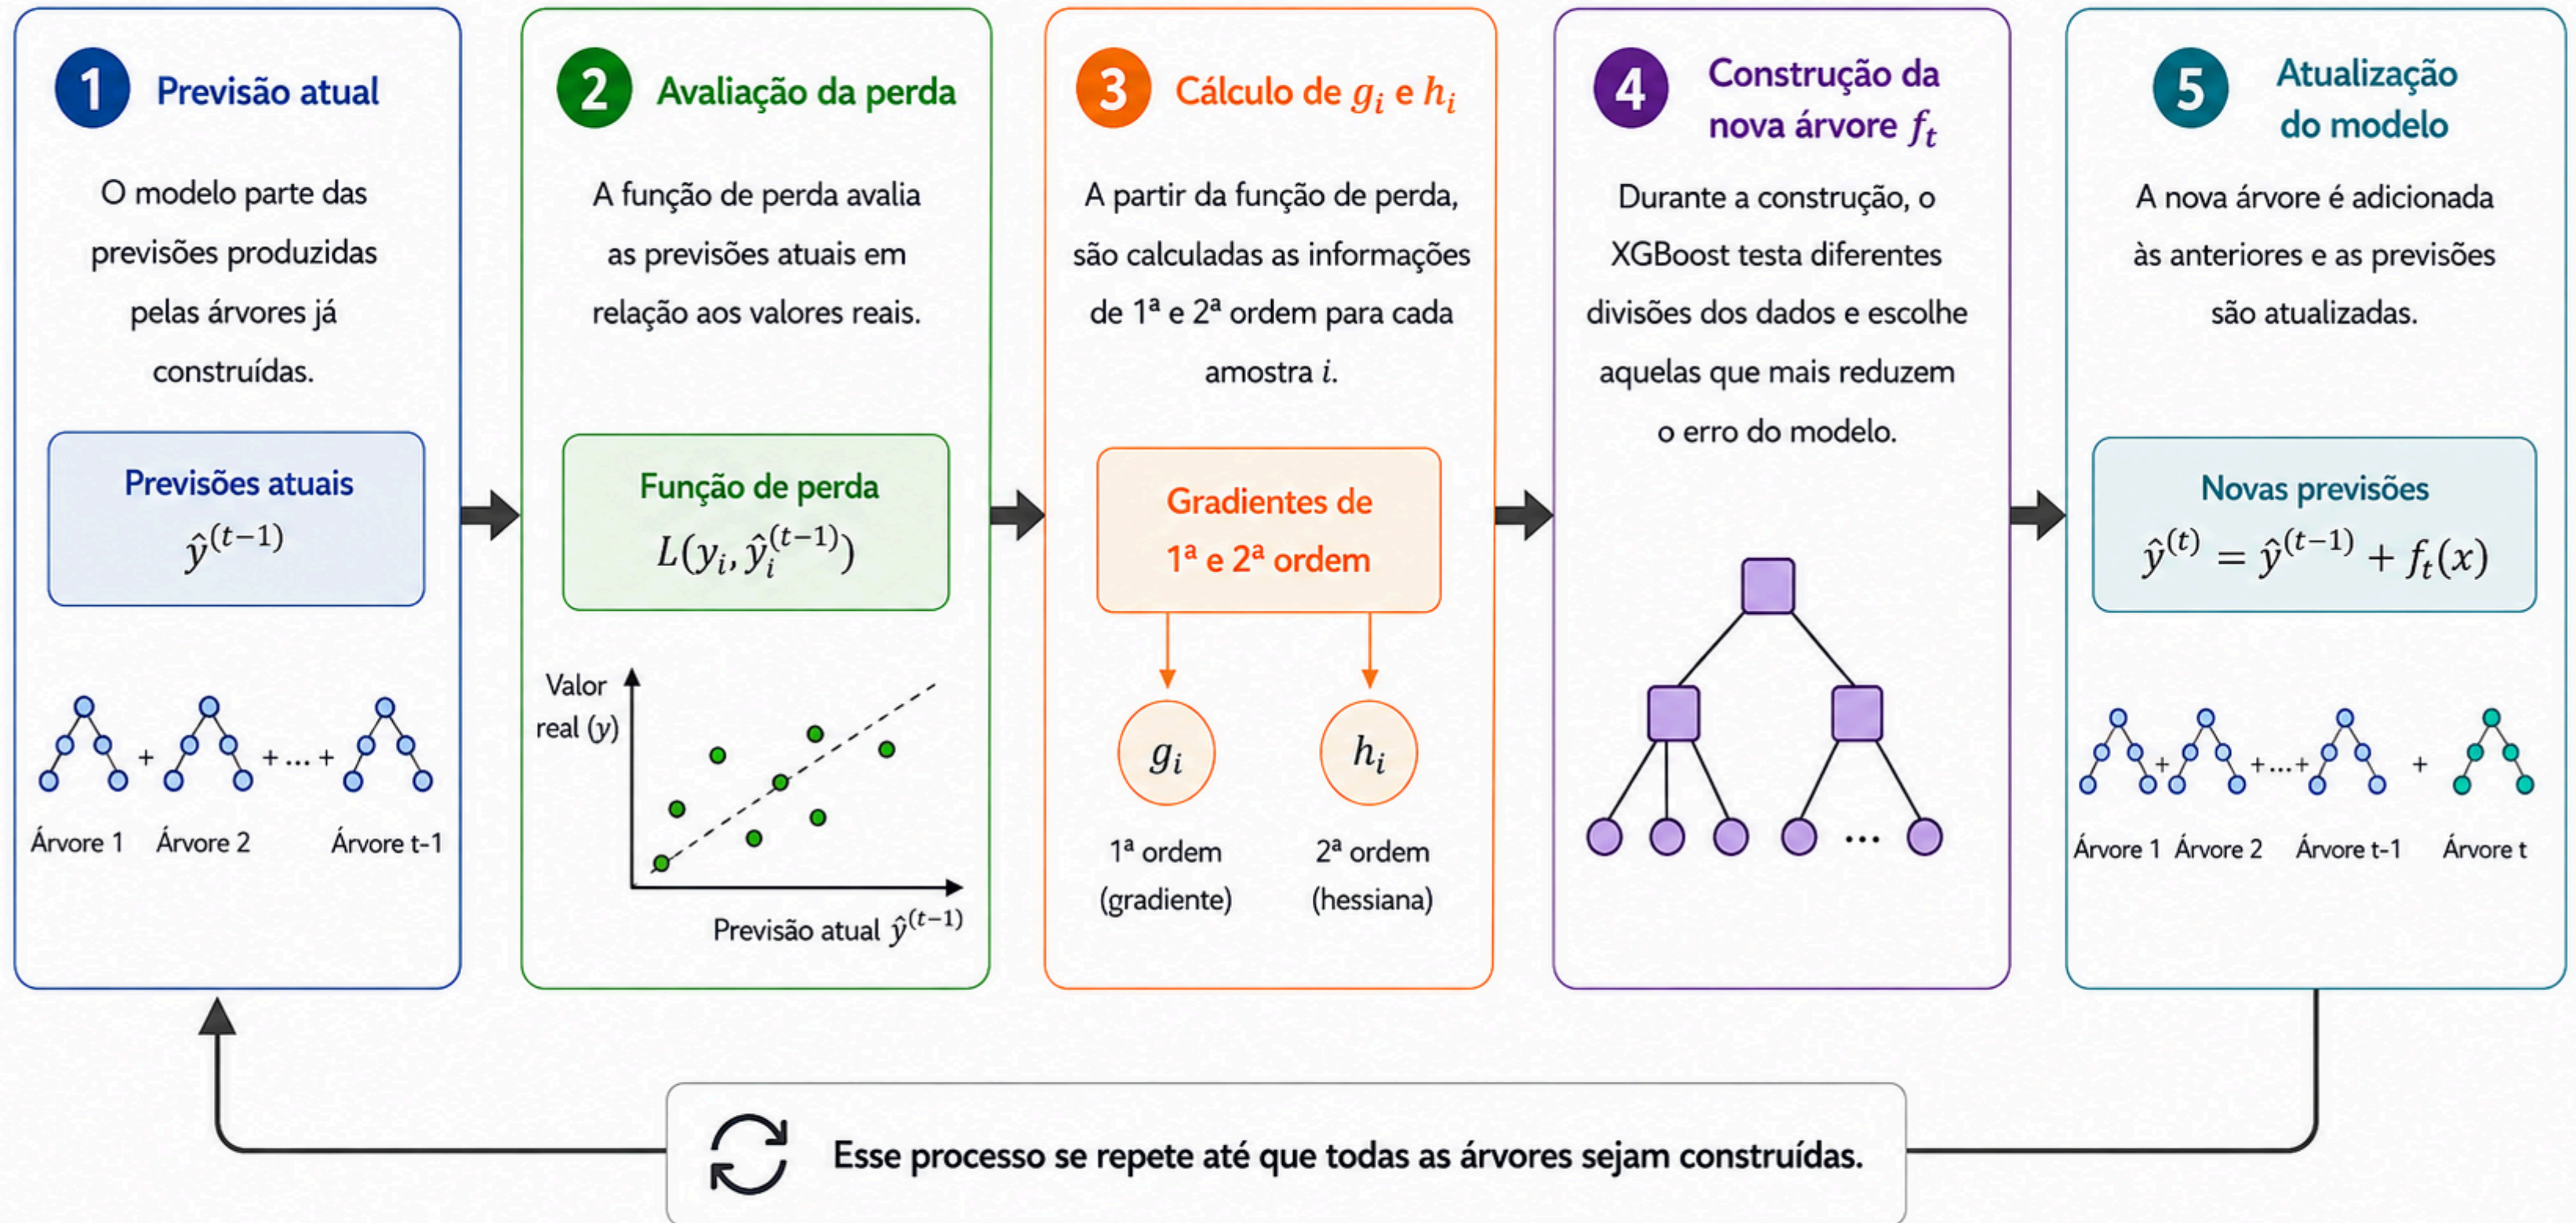
h_i : fornece informação sobre a curvatura da função de perda.

$$g_i + h_i$$

→

Otimização da nova árvore

- Como o XGBoost constrói as árvores de forma incremental?



Trabalhos relacionados mais importantes

Trabalho	Contribuição / relação com o XGBoost
Gradient Tree Boosting (Friedman)	Fundamenta o aprendizado sequencial por Gradient Boosting utilizado como base pelo XGBoost.
CART	Fornece fundamentos para a construção das árvores de decisão utilizadas nos modelos baseados em árvores.
LambdaMART	Aplicação de Tree Boosting voltada para problemas de <i>learning to rank</i> .
Parallel Tree Boosting	Trabalhos anteriores exploraram a paralelização da construção de árvores, relacionada ao desafio de eficiência em grande escala.

Metodologia

Base	Tamanho / atributos	Tarefa
Allstate	10 milhões / 4.227	Classificação de sinistros
Higgs Boson	10 milhões / 28	Classificação de eventos
Yahoo LTRC	473 mil / 700	<i>Learning to Rank</i>
Criteo	1,7 bilhão / 67	Previsão de <i>click-through rate</i>

Abordagem proposta pelo XGBoost


Técnicas	Função
Exact Greedy	Encontra a melhor divisão dos dados.
Approximate Algorithm	Utiliza candidatos a split para reduzir o custo da busca em grandes conjuntos de dados.
Weighted Quantile Sketch	Determina candidatos a split de forma eficiente considerando os pesos dos dados.
Sparsity-Aware	Trata dados esparsos automaticamente.
Cache-Aware	Otimiza o acesso aos dados na memória

Resultados


Table 3: Comparison of Exact Greedy Methods with 500 trees on Higgs-1M data.

Method	Time per Tree (sec)	Test AUC
XGBoost	0.6841	0.8304
XGBoost (colsample=0.5)	0.6401	0.8245
scikit-learn	28.51	0.8302
R.gbm	1.032	0.6224


Paralelização



Escalabilidade



(a) End-to-end time cost include data loading



(b) Per iteration cost exclude data loading

Análise crítica

Pontos fortes

- Eficiência e escalabilidade demonstradas experimentalmente.
- Solução integrada: avanços algorítmicos + otimizações de sistema.
- Capacidade de lidar com dados esparsos e grandes volumes de dados.
- Suporte a processamento paralelo, distribuído e out-of-core..

Limitações

- A eficiência é obtida com maior complexidade do sistema.
- O desempenho das otimizações pode depender dos dados e dos recursos computacionais.
- Os experimentos enfatizam principalmente eficiência e escalabilidade.
- O trabalho poderia explorar de forma mais ampla o custo/benefício das diferentes otimizações.

Possíveis Melhorias

Simplificação da configuração

- Facilitar o ajuste das diferentes otimizações e parâmetros do XGBoost.

Avaliação em novos cenários

- Investigar o desempenho em diferentes arquiteturas e condições computacionais.

Aplicações

Classificação

- Problemas com grandes conjuntos de dados.

Ranqueamento

- Ordenação de resultados e sistemas de busca.

Problemas de grande escala

- Cenários que exigem processamento paralelo, distribuído ou out-of-core.

Conclusão

Síntese do trabalho

- XGBoost torna o Tree Boosting mais eficiente e escalável.
- Combina avanços algorítmicos com otimizações computacionais.

Principais resultados

- Menor tempo de processamento nos experimentos apresentados.
- Uso eficiente de paralelismo e processamento distribuído.
- Capacidade de lidar com grandes volumes de dados por meio de out-of-core.

Impacto

- Redução do tempo de processamento.
- Capacidade de trabalhar com grandes volumes de dados.
- Suporte a processamento paralelo, distribuído e out-of-core.

Perguntas ?

Referências

- CHEN, T.; GUESTRIN, C. XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16), New York: ACM, 2016, p. 785–794
- RIEDMAN, J. H. Greedy Function Approximation: A Gradient Boosting Machine. The Annals of Statistics, 2001, p. 1189–1232.
- BREIMAN, L.; FRIEDMAN, J. H.; OLSHEN, R. A.; STONE, C. J. Classification and Regression Trees. Chapman & Hall, 1984.

Obrigada!

Quiz: <https://forms.gle/MyZocwmZ1brzVNs9A>