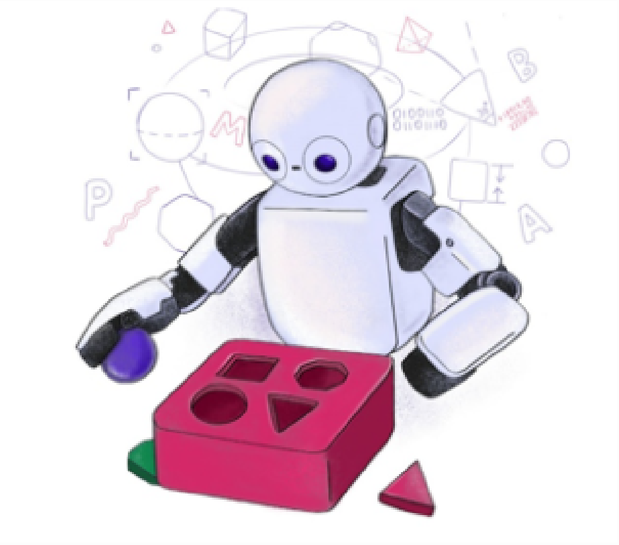
TP558 - Tópicos Avançados em Machine Learning:

LSTM (Long Short-Term Memory)



Inatel

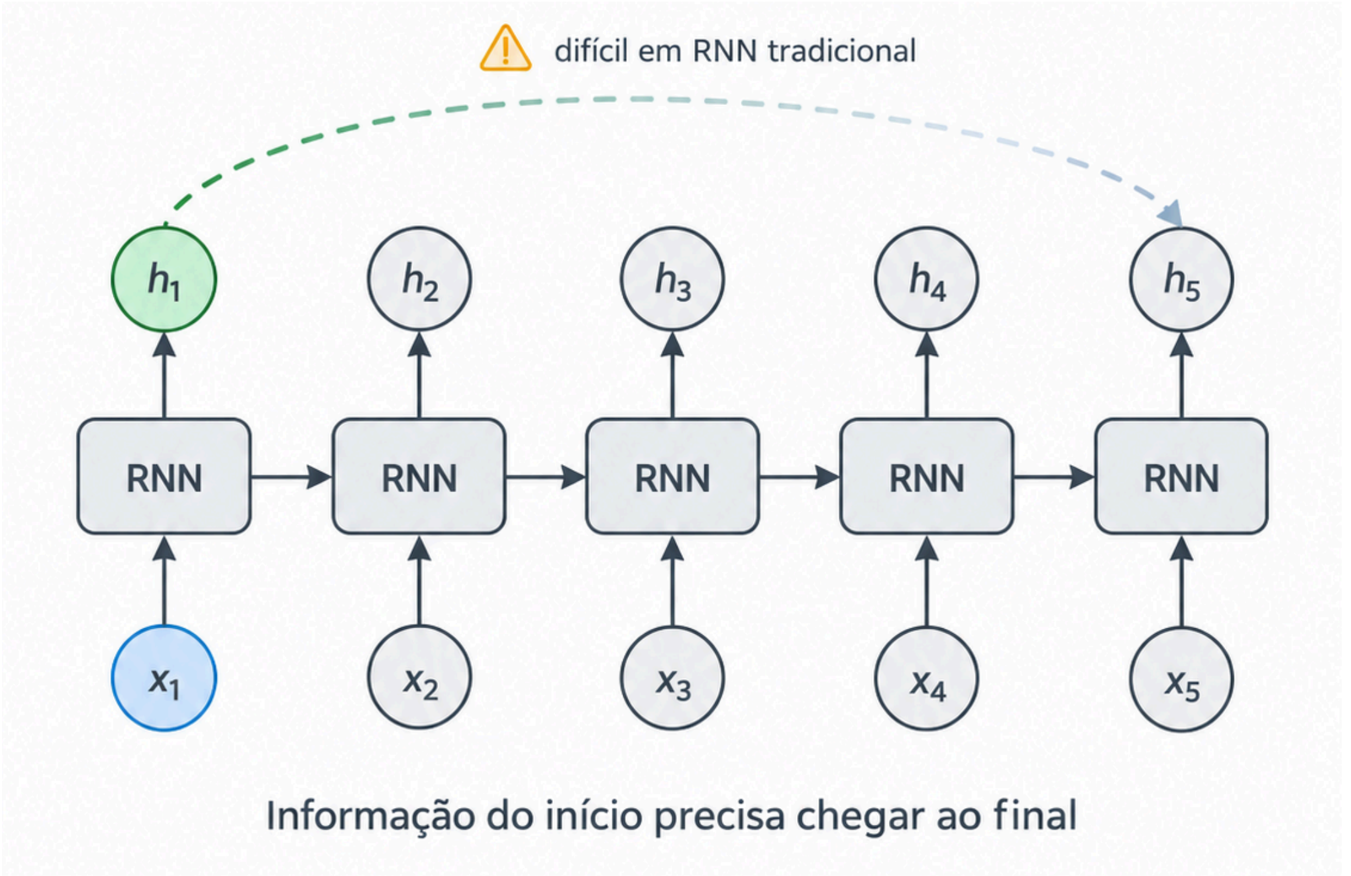
Agiana Janira Pena Marques da Silva
agiana.silva@mtel.inatel.br

Abertura

- Contexto
  - Redes Neurais Recorrentes (RNNs) são utilizadas no processamento de dados sequenciais, utilizando informações anteriores para auxiliar no processamento das informações atuais.

- Problema
  - RNNs tradicionais apresentam dificuldade em aprender dependências de longo prazo, quando informações relevantes estão muito distantes dentro da sequência.

- Motivação
  - A LSTM foi proposta para melhorar o aprendizado dessas dependências, permitindo preservar informações relevantes por períodos mais longos.



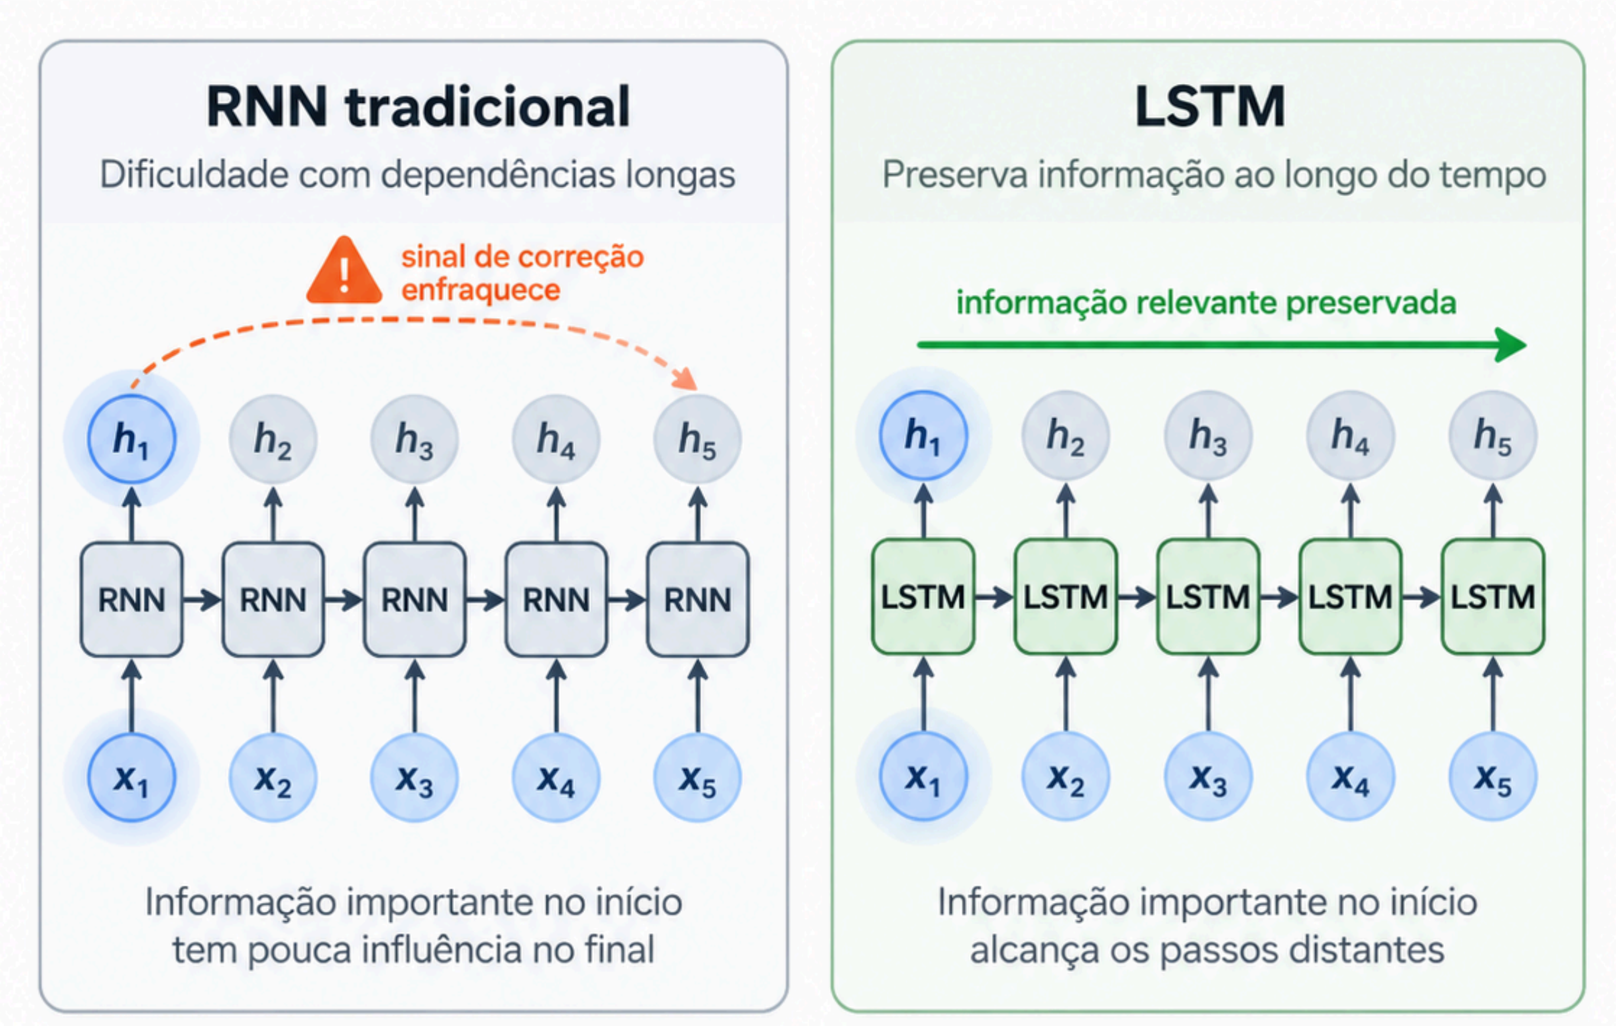
Introdução

OBJETIVO

- Apresentar a LSTM como uma nova arquitetura de rede recorrente, capaz de aprender dependências de longo prazo de maneira mais eficiente, evitando os problemas do fluxo de erro das RNNs tradicionais.

Hipótese

- Se o fluxo de erro constante for mantido ao longo do tempo, a rede poderá aprender dependências de longo prazo com mais eficiência do que as RNNs tradicionais.



Contribuições dos autores

1. Proposição da arquitetura LSTM

Desenvolvimento de uma nova arquitetura recorrente voltada ao aprendizado de dependências de longo prazo, reduzindo os problemas de desaparecimento e explosão do sinal de erro.

2. Introdução de células de memória e mecanismos de controle

Criação de células de memória baseadas no Constant Error Carousel (CEC), associadas às portas de entrada (input gate) e saída (output gate), responsáveis por controlar o armazenamento e o acesso às informações.

3. Desenvolvimento de um algoritmo de treinamento eficiente

Proposição de um método de aprendizagem baseado em gradiente, com complexidade de atualização O(W) permitindo o treinamento da LSTM de forma computacionalmente eficiente.

4. Validação experimental da proposta

Demonstração de que a LSTM consegue aprender dependências temporais muito longas, inclusive superiores a 1000 passos, obtendo mais execuções bem-sucedidas e aprendizado mais rápido que diversos métodos recorrentes anteriores.

Fundamentação Teórica

- Propagação do erro em RNNs

Treinamento de redes recorrentes

- BPTT: propaga o sinal de erro para trás ao longo dos passos temporais.
- RTRL: atualiza o aprendizado continuamente durante o processamento da sequência.

Propagação do erro

Durante a retropropagação, o sinal de erro sofre multiplicações sucessivas envolvendo os pesos e as derivadas das funções de ativação.

$$|f'(net) \cdot w| < 1 \Rightarrow \text{Vanishing Gradient}$$

$$|f'(net) \cdot w| > 1 \Rightarrow \text{Exploding Gradient}$$

Consequência

- Vanishing gradient: o sinal de correção enfraquece progressivamente.
- Exploding gradient: o sinal de correção cresce excessivamente.
- Em ambos os casos, torna-se difícil aprender relações entre informações muito distantes na sequência.

- Constant Error Carousel (CEC)

Ideia central

Criar um caminho recorrente no qual o sinal de erro possa ser propagado ao longo do tempo sem ser continuamente reduzido ou ampliado.

Condição para fluxo constante

$$f_j'(net_j(t))\, w_{jj} = 1$$

Implementação proposta pelos autores

$$f_j(x) = x \qquad \text{e} \qquad w_{jj} = 1$$

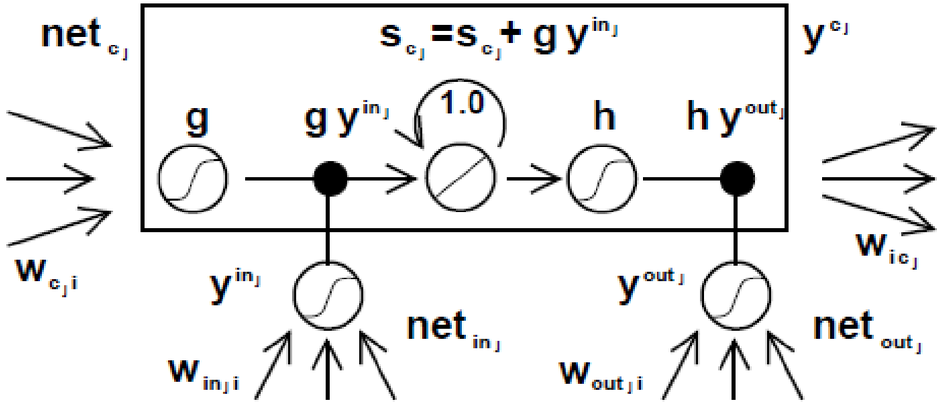
$$1 \times 1 = 1$$

Consequência

- Função identidade → derivada igual a 1.
- Auto-conexão → peso fixo igual a 1.
- O sinal não sofre redução ou ampliação sucessiva.
- Essa estrutura recebe o nome de Constant Error Carousel (CEC) e constitui a característica central da LSTM original.

- Célula de memória e mecanismos de controle

Estrutura da célula LSTM



Input gate
- controla a entrada de novas informações.

CEC
- mantém o conteúdo armazenado ao longo do tempo.

Output gate
- controla quando o conteúdo armazenado pode ser utilizado.

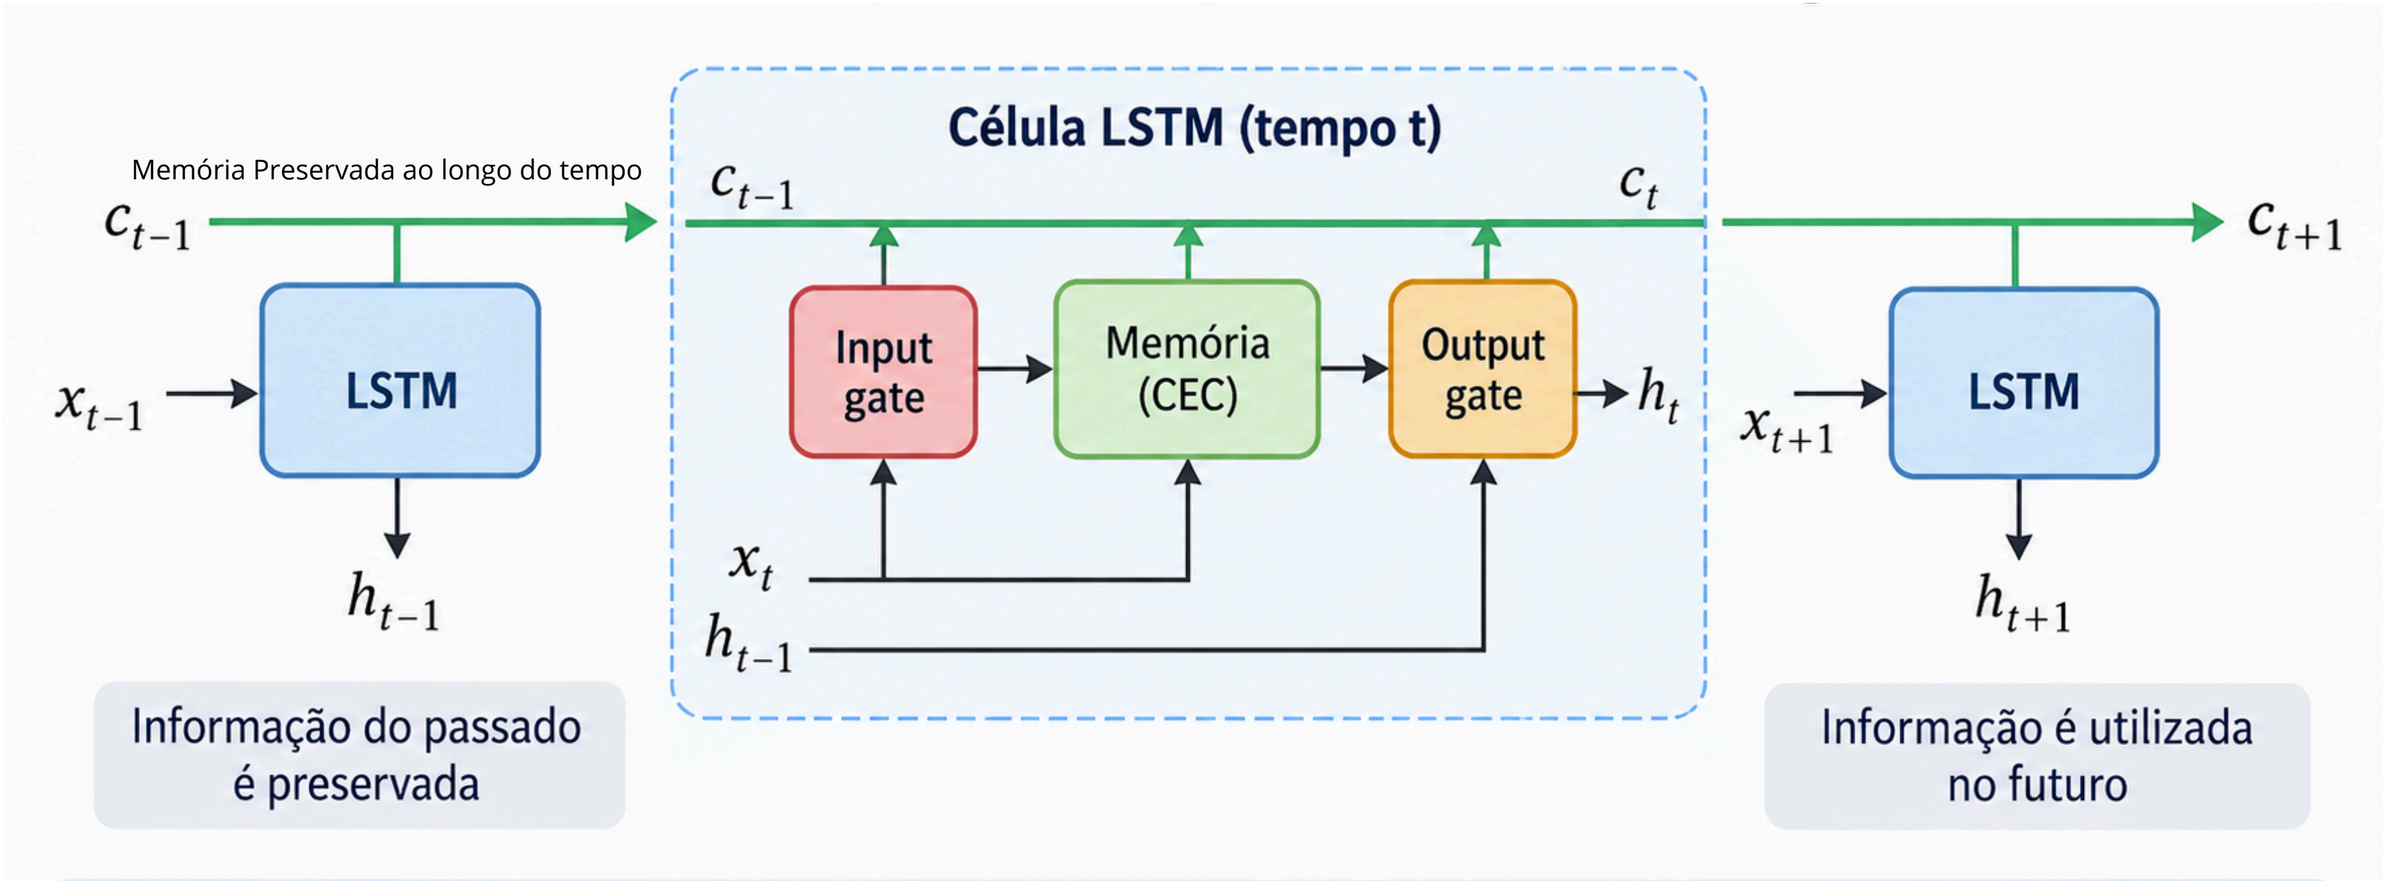
Atualização do estado interno

$$s_{c_j}(t) = s_{c_j}(t-1) + y_{in_j}(t)\, g(net_{c_j}(t))$$

Saída da célula

$$y_{c_j}(t) = y_{out_j}(t)\, h(s_{c_j}(t))$$

Como a LSTM aprende dependências de longo prazo



Treinamento da LSTM original

Aprendizagem

Erro na saída

- propagação do erro para trás
- dentro do CEC, o erro atravessa estados anteriores sem sofrer escalamentos sucessivos
- fora da célula, a propagação temporal é truncada
- o erro é utilizado para atualizar os pesos

Treinamento:

variante do RTRL adaptada aos mecanismos multiplicativos dos input e output gates.



- Trabalhos Relacionados

Trabalho relacionado	**O que foi aproveitado / relação com a LSTM**
Untersuchungen zu dynamischen neuronalen Netzen (1991)	A análise do desaparecimento e crescimento exponencial do erro serviu como **base teórica para a criação do CEC**, cujo objetivo é manter um fluxo de erro constante.
Learning Long-Term Dependencies with Gradient Descent is Difficult (1994)	Reforçou a **necessidade de uma nova solução para aprender dependências de longo prazo** com métodos baseados em gradiente.
Induction of Finite-State Languages Using Second-Order Recurrent Networks (1992)	Já utilizava **unidades multiplicativas**; na LSTM, essas unidades são empregadas nos *gates* para controlar o acesso ao fluxo constante de erro.
Learning Complex, Extended Sequences Using the Principle of History Compression (1992)	Mostrou uma forma de atravessar **grandes intervalos temporais**; suas limitações com ruído e baixa previsibilidade ajudaram a evidenciar a necessidade de uma solução mais robusta, como a LSTM.

Evolução da arquitetura LSTM

LSTM original - 1997	**LSTM com forget gate - evolução posterior**
Input gate	*Input gate*
Output gate	*Output gate*
CEC com auto-conexão de peso 1	Memória com retenção controlada pelo forget gate
Não possui forget gate	**Inclui forget gate**
O estado interno tende a acumular informação	O *forget gate* permite controlar quanto da memória anterior deve ser mantido ou descartado

Metodologia

Experimento	**Objetivo metodológico**
Experimento 1 - Embedded Reber Grammar	Verificar o funcionamento inicial da LSTM em um teste padrão de comparação conhecido e evidenciar a importância do output gate.
Experimento 2 - Noise-Free and Noisy Sequences	Testar a preservação de informação relevante por longos intervalos, com ruído e atrasos da ordem de 1000 passos.
Experimento 3 - Noise and Signal on Same Channel	Verificar se a LSTM separa e mantém a informação relevante quando sinal e ruído aparecem no mesmo canal.
Experimento 4 - Adding Problem	Avaliar o armazenamento de valores contínuos por longos períodos e seu uso posterior em uma soma.
Experimento 5 - Multiplication Problem	Verificar se a LSTM resolve uma tarefa de longo prazo não integrativa, baseada em multiplicação.
Experimento 6 - Temporal Order	Testar o aprendizado da ordem temporal entre símbolos relevantes amplamente separados no tempo.

1. Arquitetura empregada (modelo usado)

- LSTM original proposta em 1997.
- Rede organizada em camada de entrada, camada oculta e camada de saída.
- A camada oculta contém células de memória e suas unidades de controle, organizadas em memory cell blocks.

2. Algoritmo de aprendizagem (treinamento)

- Variante do RTRL, adaptada aos input e output gates.
- Erro truncado fora das células de memória.
- Erro preservado dentro da célula por meio do CEC.

3. Métodos utilizados para comparação

RTRL · BPTT · Elman Networks · Recurrent Cascade Correlation · Neural Sequence Chunking

Resultados

Método	**Taxa de sucesso**	**Sequências até sucesso**
RTRL	sucesso parcial	25.000 / 173.000
Elman	0%	>200.000
RCC	50%	182.000
LSTM	100%	8.440

Dependências de longo prazo

Método	**Atraso de 100 passos**	**Taxa de sucesso**
RTRL	100	0%
BPTT	100	0%
Neural Sequence Chunker	100	33%
LSTM	100	100%

Robustez da LSTM

Experimento	**Resultado principal**
3 - Ruído e sinal	LSTM conseguiu separar informação relevante do ruído
4 - Adding Problem	Armazenou e processou valores contínuos por longos períodos
5 - Multiplication Problem	Resolveu também uma tarefa não integrativa
6 - Temporal Order	Aprendeu a ordem de eventos separados no tempo

Análise crítica

Pontos Fortes

- Solução arquitetural específica para o problema do vanishing/exploding gradient, por meio do CEC e dos gates.
- Bom desempenho em dependências temporais muito longas, inclusive com ruído, valores contínuos e representações distribuídas.
- Algoritmo eficiente: complexidade de atualização O(1) por peso e passo temporal.

Limitações

- A arquitetura ainda apresenta dificuldade em alguns problemas mais específicos, como tarefas que exigem contagem temporal muito precisa.
- Maior complexidade estrutural: cada bloco de memória necessita de unidades adicionais para os input e output gates, aumentando o número de unidades e pesos em comparação com uma RNN convencional.
- A retropropagação truncada apresenta dificuldade em algumas tarefas não decomponíveis, nas quais informações muito distantes precisam ser combinadas para produzir a resposta.”

Possíveis Melhorias

- Incorporar mecanismos adicionais para tarefas que exigem contagem temporal muito precisa.
- Combinar a LSTM com outros métodos de processamento de sequências.
- Avaliar a arquitetura em dados reais, já que os experimentos do artigo são artificiais.

Aplicações

- Previsão de séries temporais
- Composição musical
- Processamento de fala
- Combinação com métodos de sequence chunking

Conclusão

- A LSTM foi proposta para enfrentar o problema do desaparecimento e explosão do erro em dependências temporais longas.
- O CEC permite preservar o fluxo de erro ao longo do tempo.
- Input gate e output gate controlam o acesso à memória.
- Nos experimentos, a LSTM apresentou maior capacidade de aprender dependências longas que vários métodos recorrentes comparados.
- Também apresentou bom desempenho com ruído, valores contínuos e ordem temporal.
- Apesar dos resultados positivos, a arquitetura original apresenta limitações e os próprios autores apontam a necessidade de testes em aplicações reais.

Perguntas ?

Referências

1. S. Hochreiter and J. Schmidhuber, “Long Short-Term Memory,” Neural Computation, vol. 9, pp. 1735–1780, 1997.
2. F. A. Gers, J. Schmidhuber, and F. Cummins, “Learning to Forget: Continual Prediction with LSTM,” in Artificial Neural Networks, IEE Conference Publication No. 470, pp. 850–855, 1999.
3. C. Olah, “Understanding LSTM Networks,” 2015.

Obrigada!

Quiz:

https://docs.google.com/forms/d/e/1FAIpQLSeKINam7QDRMKr3bb_ULBoXlv5XJDPzpf5sMdm24BxC_M2CPw/viewform?usp=dialog