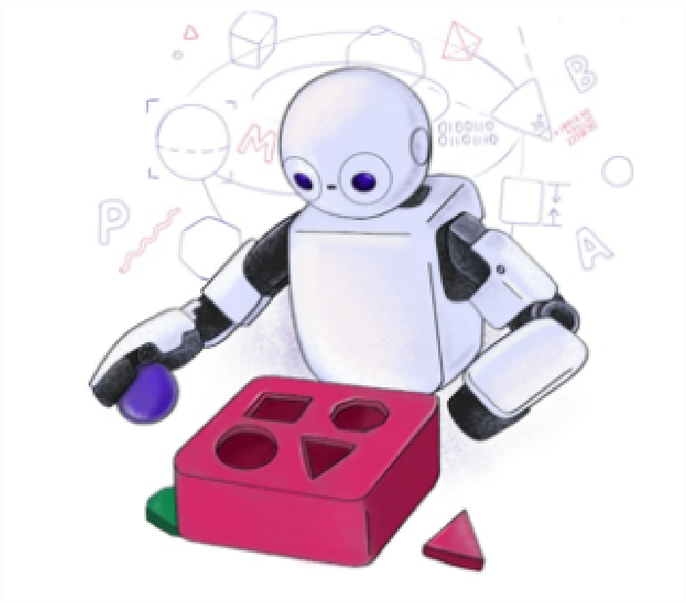
TP558 - Tópicos Avançados em Machine Learning:

TabNet: Attentive Interpretable Tabular Learning



Inatel

Agiana Janira Pena Marques da Silva
agiana.silva@mtel.inatel.br

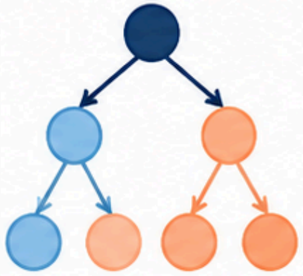
Abertura

Contexto do tema

- Dados tabulares são muito comuns em aplicações reais.
- Modelos baseados em árvores apresentam forte desempenho nesse tipo de dado.

Idade	Profissão	Renda	...
25	Engenheiro	Alta	...
32	Professor	Média	...
28	Analista	Alta	...
...	...	...	...

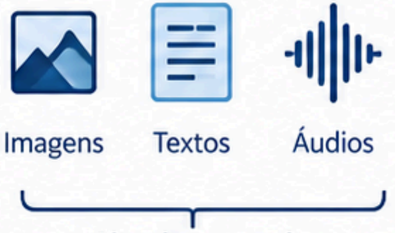
Dados tabulares



Modelos baseados em árvores (ex.: XGBoost)

Problema geral da área

- Redes neurais profundas têm grande sucesso em imagens, textos e áudios.
- Porém, seu desempenho em dados tabulares ainda é mais limitado.



Alto desempenho com redes neurais profundas

≠

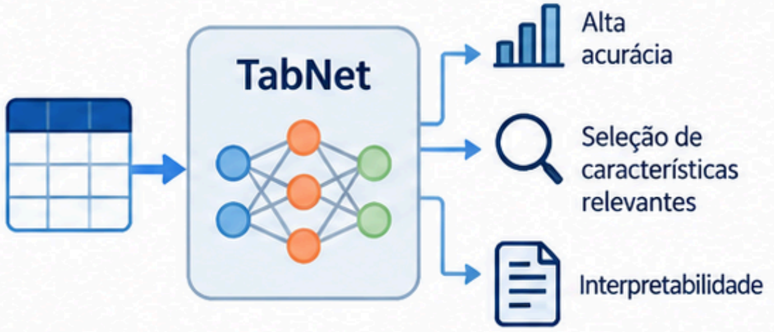


Dados tabulares

Desempenho mais limitado

Motivação do artigo

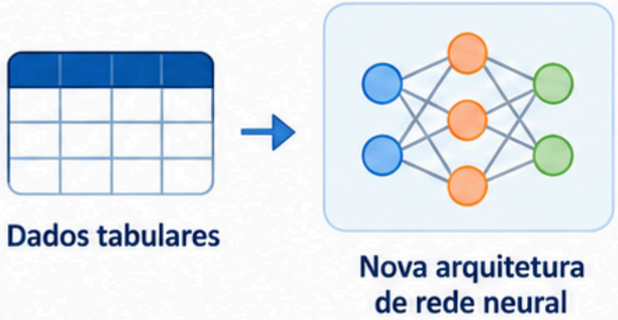
- Desenvolver uma arquitetura de rede neural específica para dados tabulares.
- Selecionar automaticamente as características mais relevantes.
- Tornar as decisões do modelo mais interpretáveis.



Introdução

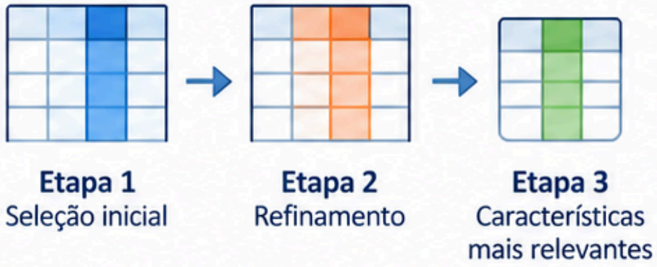
Objetivo

- Propor uma nova arquitetura de rede neural para dados tabulares.
- Melhorar o desempenho sem perder a interpretabilidade.



Hipótese

- Selecionar, em cada etapa, as características mais relevantes pode melhorar o aprendizado.
- Essa estratégia pode tornar o modelo mais eficiente e mais interpretável.



Contribuições declaradas pelos autores

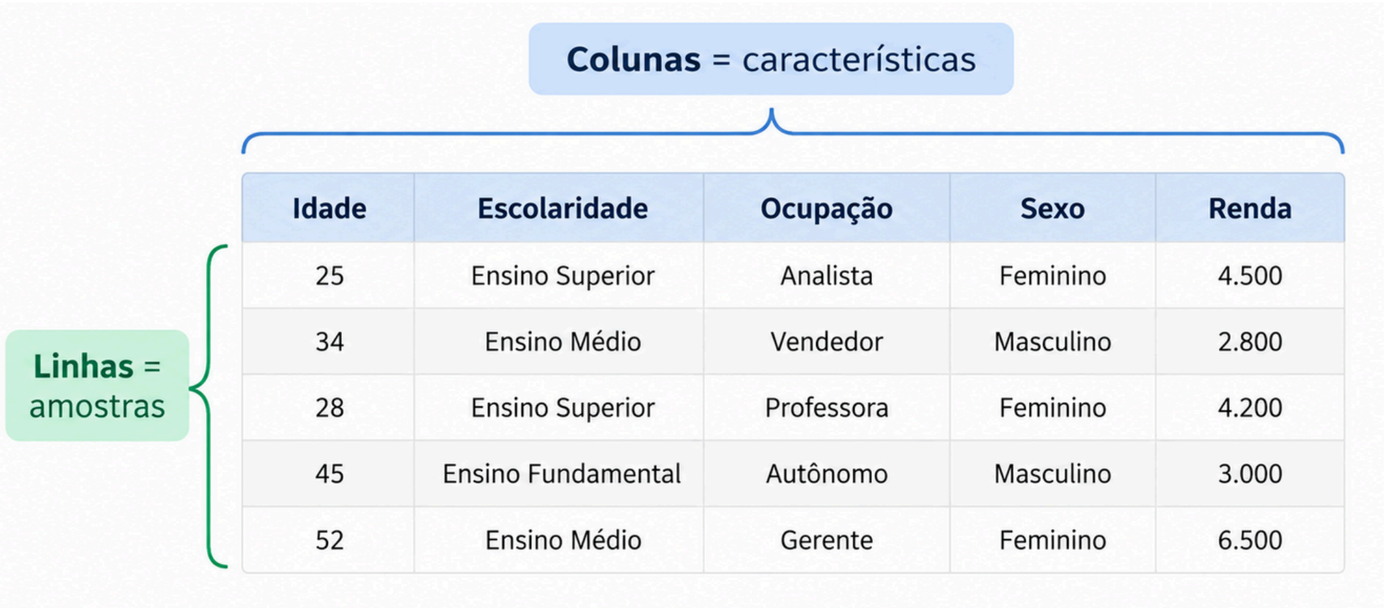
- Uso direto de dados tabulares com pouco pré-processamento.
- Seleção sequencial das características mais relevantes.
- Interpretabilidade local e global.
- Pré-treinamento auto-supervisionado para melhorar o desempenho.



Fundamentação Teórica

Dados tabulares:

- Dados organizados em linhas e colunas.
- Cada linha representa uma observação ou exemplo.
- Cada coluna representa uma característica (feature).
- Podem conter valores numéricos e categóricos.



Idade	Escolaridade	Ocupação	Sexo	Renda
25	Ensino Superior	Analista	Feminino	4.500
34	Ensino Médio	Vendedor	Masculino	2.800
28	Ensino Superior	Professora	Feminino	4.200
45	Ensino Fundamental	Autônomo	Masculino	3.000
52	Ensino Médio	Gerente	Feminino	6.500

Funcionamento

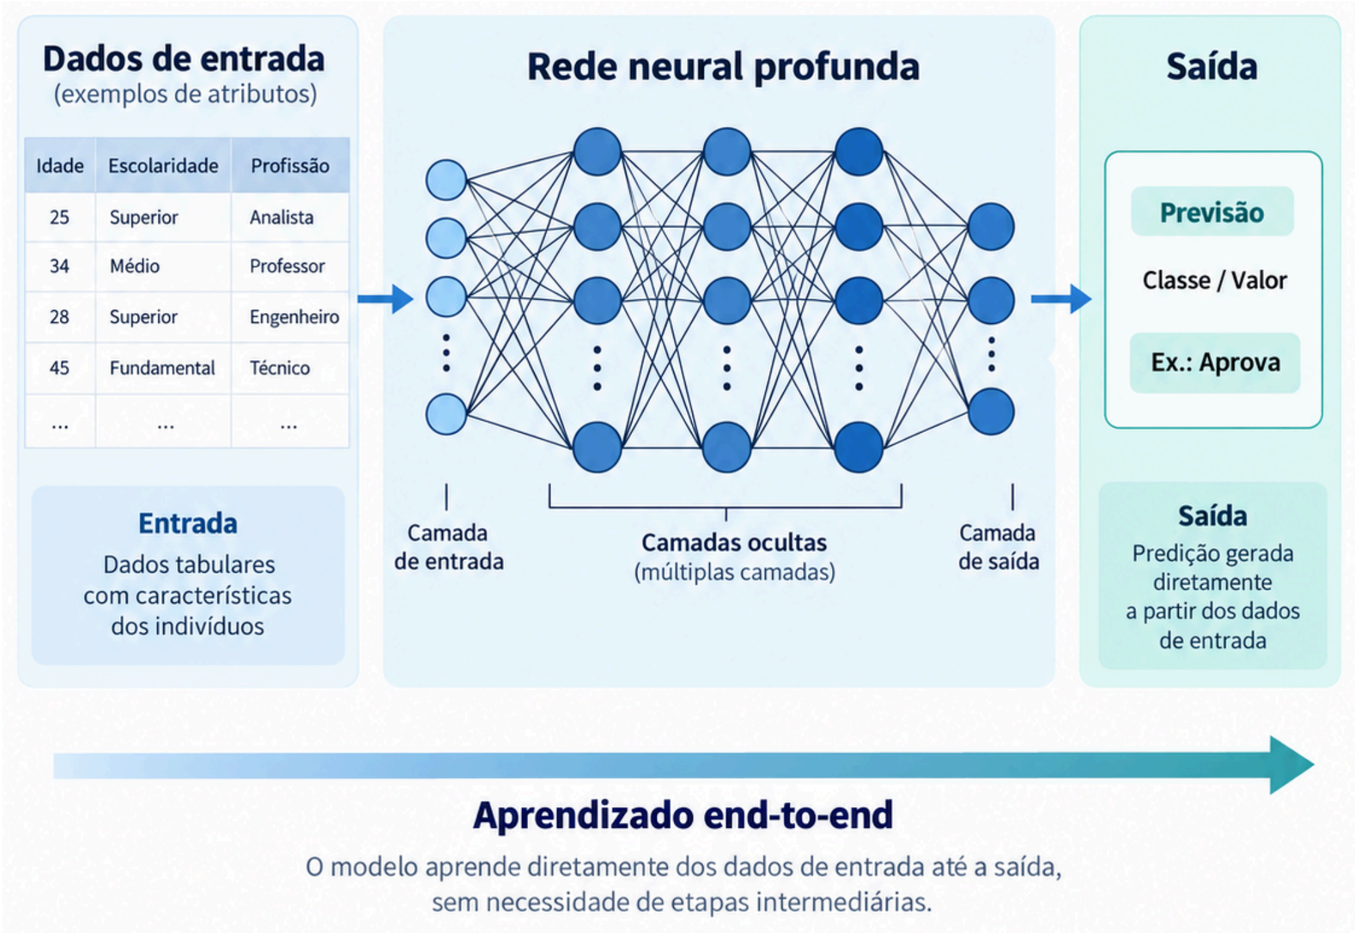
- O modelo recebe as características de cada linha como entrada.
- Essas características são utilizadas para identificar relações entre os dados.
- A partir dessas relações, o modelo aprende a realizar uma previsão, como uma classe ou um valor.

Redes neurais profundas

- Formadas por várias camadas de processamento.
- Aprendem padrões diretamente a partir dos dados.
- Têm grande sucesso em imagens, textos e áudios.

Aprendizado end-to-end

- O modelo aprende desde a entrada até a saída final.
- Seus parâmetros são ajustados automaticamente durante o treinamento.
- Permite integrar todo o processo de aprendizado em uma única arquitetura.



Seleção de características

Ideia principal

- A TabNet aprende automaticamente quais características são mais relevantes em cada etapa.
- A seleção é feita por meio de uma máscara M[i].

Interpretação

- M[i]: peso atribuído a cada característica.
- P[i-1]: considera quanto a característica já foi utilizada.
- hi(a[i-1]): gera os valores usados para decidir a importância.
- sparsemax: força a seleção a ser esparsa, permitindo pesos iguais a zero.

Máscara de seleção

$$M[i] = \text{sparsemax}\left(P[i-1] \cdot h_i(a[i-1])\right)$$

Aplicação da máscara

$$M[i] \cdot f$$

- Processar as características selecionadas
- características importantes → peso maior;
- características irrelevantes → peso próximo de zero ou zero.

Função de perda e treinamento supervisionado

Função de perda da TabNet: Estimula a TabNet a fazer seleção concentrada, usando poucas características por etapa.

Regularização de esparsidade

$$L_{\text{sparse}} = \frac{1}{N_{\text{steps}} B} \sum_{i=1}^{N_{\text{steps}}} \sum_{b=1}^{B} \sum_{j=1}^{D} -M_{b,j}[i] \log(M_{b,j}[i] + \epsilon)$$

Perda da tarefa

- Classificação: softmax cross-entropy
- Regressão: mean squared error (MSE)

- Pesos atribuídos pela máscara
- incentiva máscaras esparsas;
- reduz o uso de características irrelevantes;
- melhora a eficiência da seleção.

Objetivo do pré-treinamento auto-supervisionado

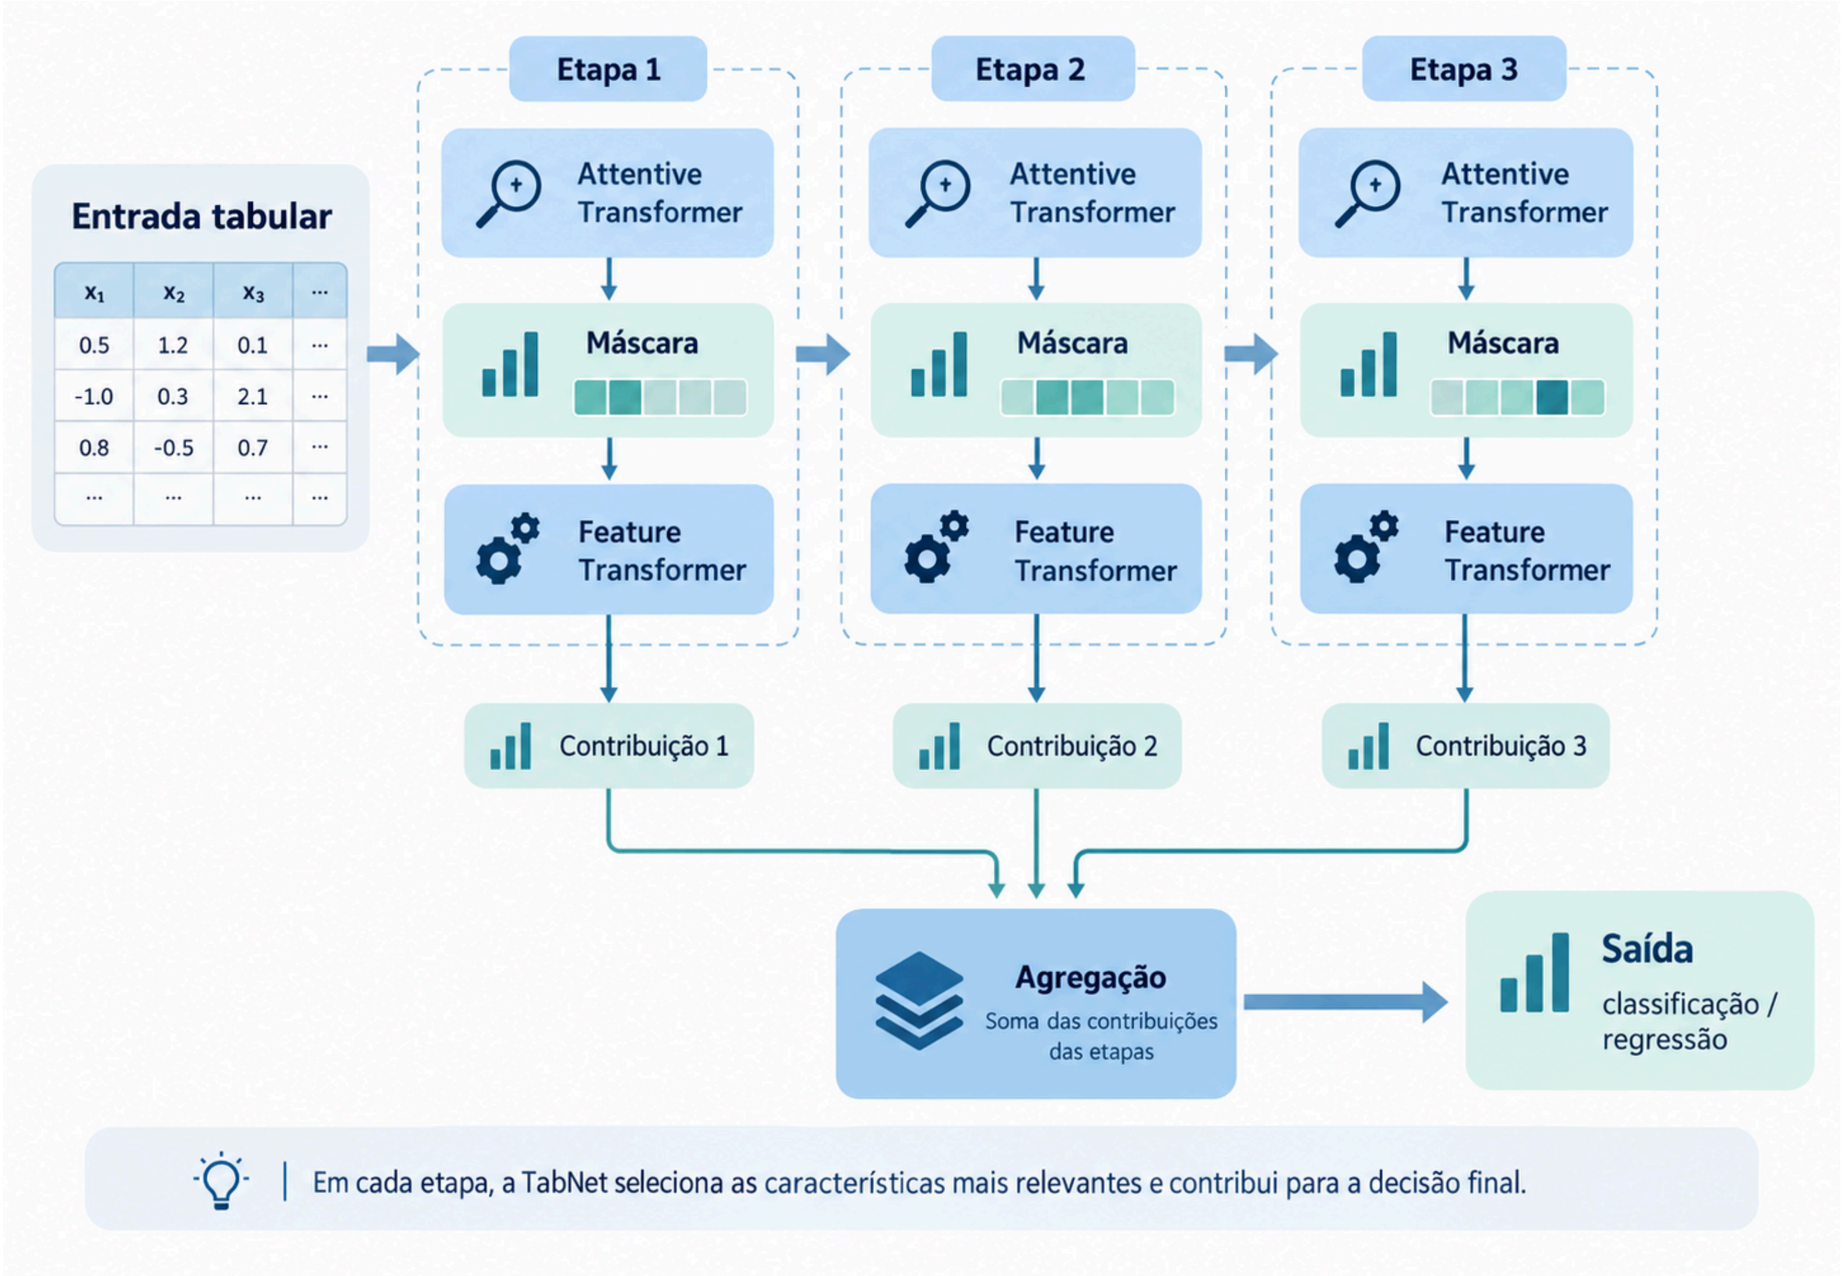
Pré-treinamento auto-supervisionado

- A tabnet aprende a relação entre os dados;
- Algumas características são escondidas;
- Encoder: processa as características disponíveis;
- Decoder tenta reconstruir as características ocultadas.
- Benefício: pode melhorar o desempenho em tarefas posteriores.

Objetivo

- prever colunas ausentes a partir das demais;
- aprender boas representações antes do ajuste supervisionado.

- **Funcionamento da TabNet**



Trabalhos relacionados mais importantes

Linha de trabalho	**Exemplos citados no artigo**	**Relação com a TabNet**
Seleção de características	Lasso, L2X, INVASE	Buscam identificar as características mais relevantes para a previsão.
Modelos baseados em árvores	Random Forest, XGBoost, LightGBM	São referências fortes para dados tabulares e fazem seleção eficiente de características.
Redes neurais inspiradas em árvores	Soft Neural Decision Trees, Deep Neural Decision Trees	Tentam combinar propriedades das árvores com redes neurais.

Metodologia

1. Bases de dados

Sintéticas

Syn1 | Syn2 | Syn3
Syn4 | Syn5 | Syn6

Reais

- Forest Cover Type
- Poker Hand
- Sarcos
- Higgs Boson
- Rossmann
- KDD
- Mushroom
- Adult Census Income

2. Tipos de tarefa



Classificação



Regressão

3. Tratamento dos dados

Categóricas → embeddings treináveis

Numéricas → entrada direta



Mesma divisão:
treino / validação / teste

4. Treinamento

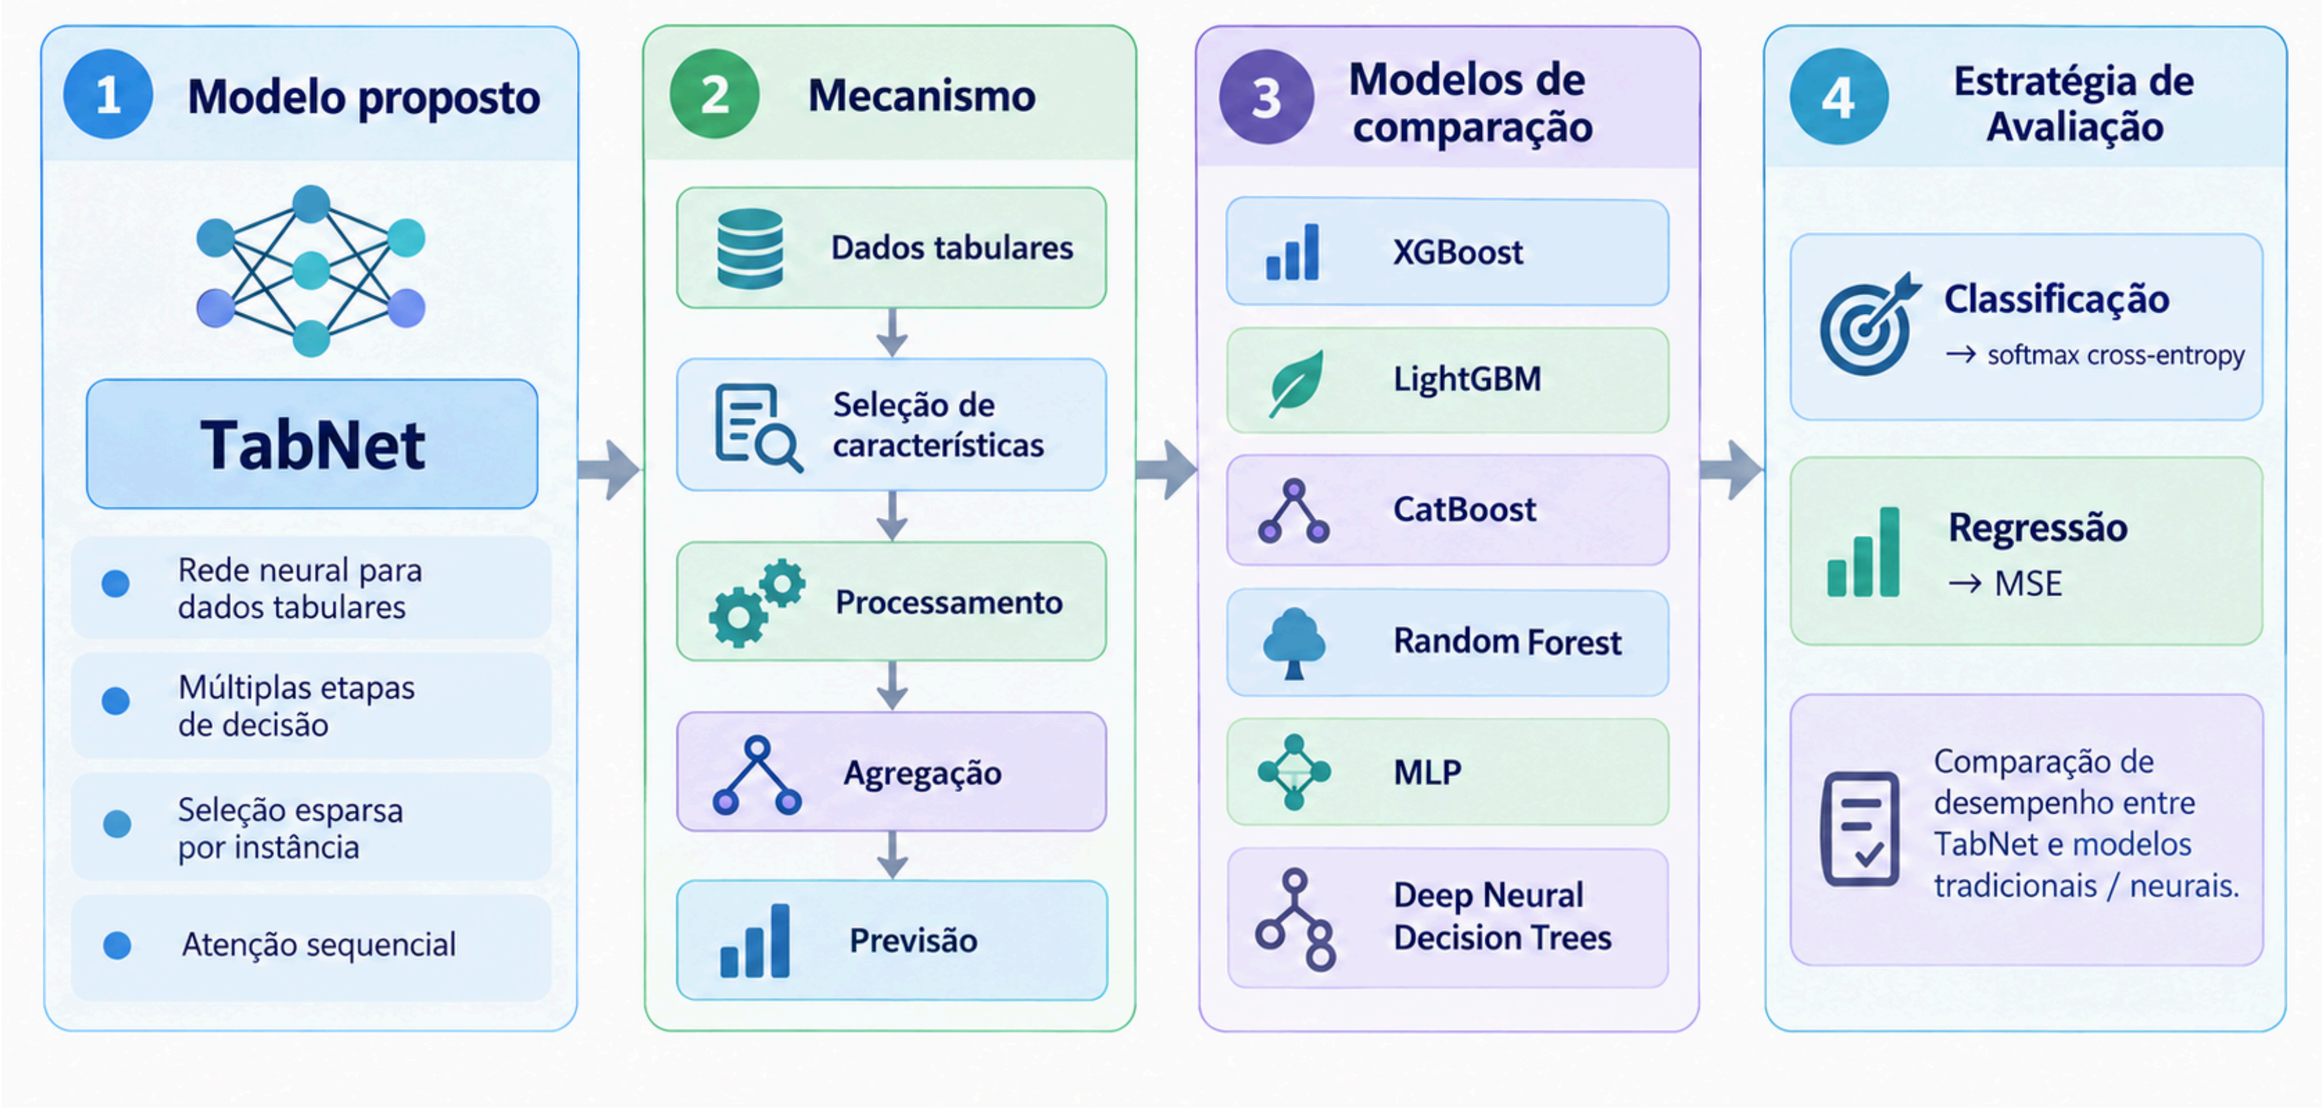
Hiperparâmetros otimizados na validação

Treinamento até convergência

Otimizador **Adam**

Inicialização **Glorot uniform**

Abordagem proposta pelo XGBoost

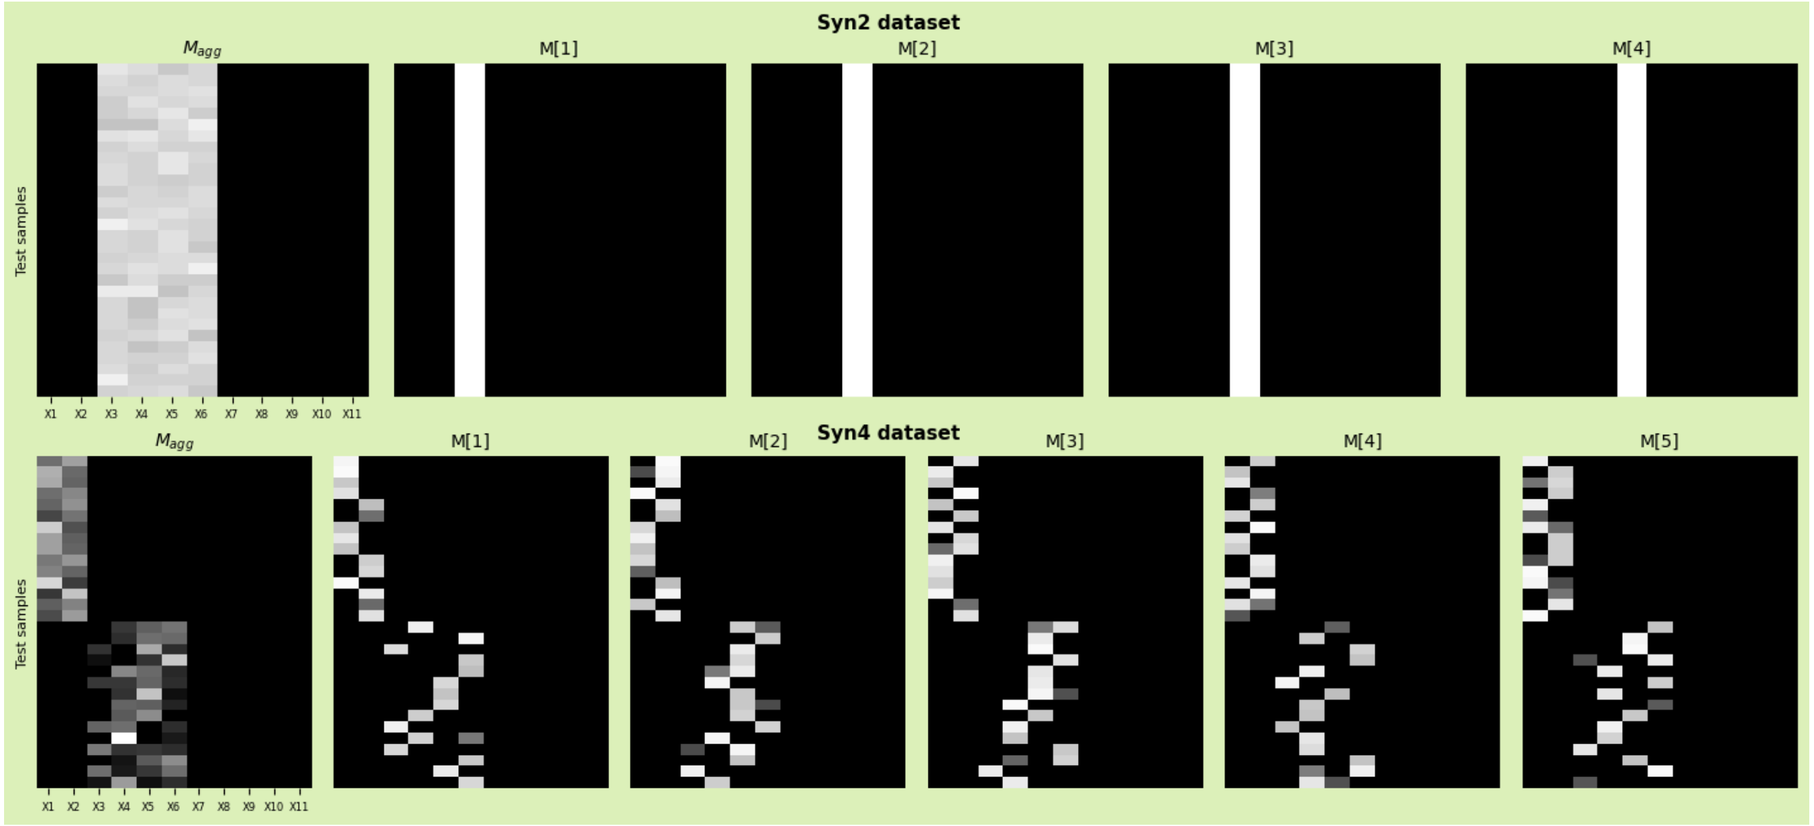


Resultados

Desempenho da TabNet

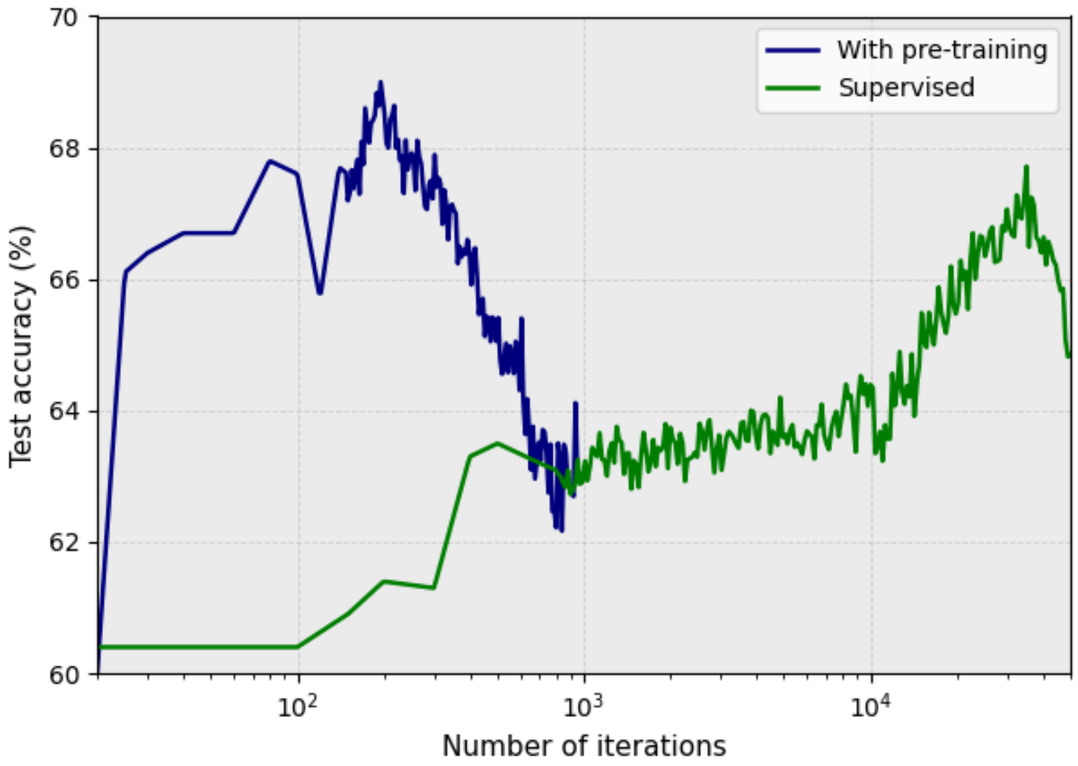
Dataset	**Tarefa**	**Principais resultados**
Forest Cover Type	Classificação	TabNet: **96,99%** - XGBoost: 89,34% - LightGBM: 89,28%
Poker Hand	Classificação	TabNet: **99,2%** - XGBoost: 71,1% - LightGBM: 70,0%
Sarcos	Regressão	TabNet-L: **0,14 MSE** - Gradient Boosted Tree: 1,44 - Random Forest: 2,39
Rossmann Store Sales	Regressão	TabNet: **485,12 MSE** - CatBoost: 489,75 - XGBoost: 490,83

Interpretabilidade e seleção de características



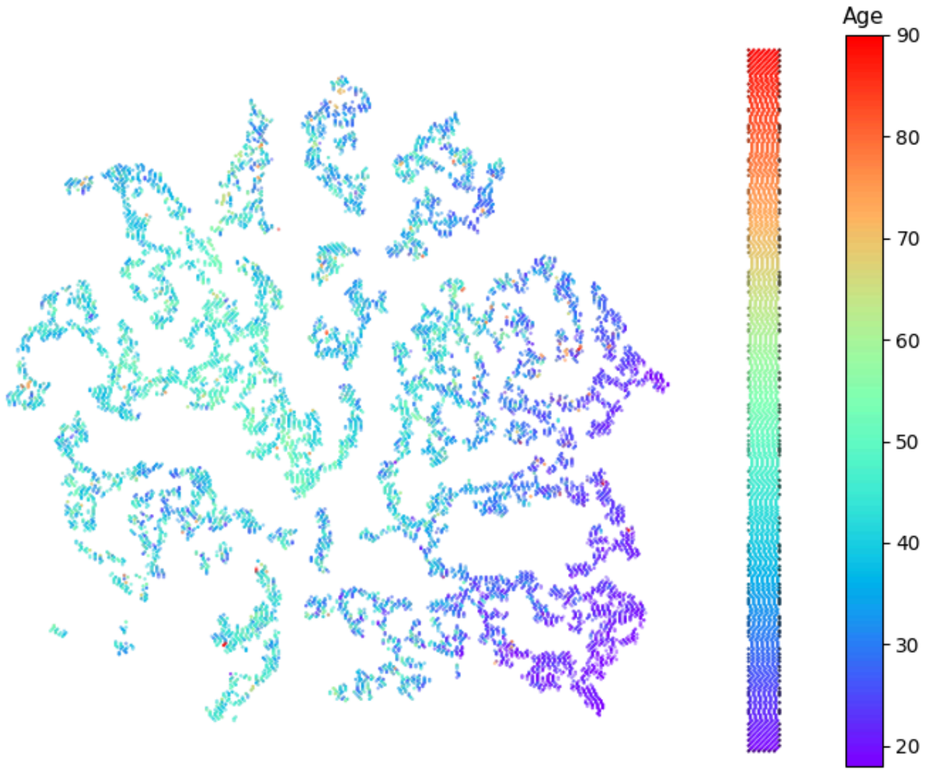
Reprodução ilustrativa inspirada na Figura 5 do artigo.

Efeito do pré-treinamento auto-supervisionado



Reprodução ilustrativa da Figura 7, baseada no comportamento visual apresentado no artigo.

Interpretabilidade da representação aprendida



Reprodução ilustrativa da Figura 6, inspirada no comportamento visual apresentado no artigo.

Pontos fortes

- Seleção de características por instância
- Interpretabilidade integrada ao próprio modelo
- Bom desempenho em diferentes tarefas tabulares
- Arquitetura única para seleção e previsão

Limitações

- Não supera todos os modelos em todos os datasets
- Benefício do pré-treinamento diminui com mais dados rotulados
- Maior complexidade arquitetural
- Sensibilidade à capacidade do modelo e hiperparâmetros

Conclusão

Síntese do trabalho

- A TabNet foi desenvolvida especificamente para dados tabulares.
- Combina atenção sequencial, seleção de características por instância e interpretabilidade.
- Pode ser aplicada a tarefas de classificação e regressão.

Principais resultados

- Apresentou desempenho competitivo ou superior em vários problemas de classificação e regressão.
- No Forest Cover Type, atingiu 96,99% de acurácia; no Poker Hand, 99,2%.
- O pré-treinamento auto-supervisionado melhorou o desempenho, principalmente quando havia poucos dados rotulados, e acelerou a convergência.
- As máscaras de seleção permitiram identificar características relevantes e fornecer interpretabilidade às decisões.

Impacto

- Mostrou que uma rede neural pode competir com métodos baseados em árvores em vários benchmarks tabulares.
- Integra seleção de características e previsão em uma única arquitetura.
- Mostra que o pré-treinamento auto-supervisionado pode melhorar o desempenho e acelerar a convergência quando há poucos dados rotulados.

Perguntas ?

Refeências

- S. Ö. Arik and T. Pfister, “TabNet: Attentive Interpretable Tabular Learning,” Proceedings of the AAAI Conference on Artificial Intelligence, vol. 35, no. 8, pp. 6679–6687, 2021, doi: 10.1609/aaai.v35i8.16826.

- S. Popov, S. Morozov, and A. Babenko, “Neural Oblivious Decision Ensembles for Deep Learning on Tabular Data,” in International Conference on Learning Representations (ICLR), 2020.

- Y. Gorishniy, I. Rubachev, V. Khrulkov, and A. Babenko, “Revisiting Deep Learning Models for Tabular Data,” in Advances in Neural Information Processing Systems (NeurIPS), vol. 34, 2021.

Obrigada!

Quiz: https://forms.gle/YWjFhqcRunsrYw9x5